基于 LSTM 的多变量空气质量预测实验报告

一、简介

随着工业化和城市化进程的推进，空气污染问题逐渐成为影响居民健康和城市环境治理的重要因素。其中，PM2.5 作为衡量空气质量的重要指标之一，具有粒径小、危害大、易传播等特点，对人体呼吸系统和心血管系统均可能造成不良影响。因此，利用历史空气质量数据与气象数据对 PM2.5 浓度进行准确预测，具有较高的现实意义和应用价值。

本实验选取 Kaggle 提供的空气质量数据集作为研究对象。该数据集记录了连续多年内每小时的空气污染情况和气象信息，主要包括 PM2.5 浓度、露点、温度、气压、风向、风速、累计降雪时长和累计降雨时长等变量。由于污染物浓度的变化不仅与当前气象条件有关，还与之前一段时间内的污染累积和天气变化有关，因此该问题具有明显的时间序列特征。

本实验的主要目标是建立一个基于 LSTM 的多变量时间序列预测模型，利用过去若干小时的空气质量与气象数据，预测下一小时的 PM2.5 浓度。通过该实验，可以加深对时间序列建模、数据预处理、神经网络训练以及模型评价方法的理解。

与普通的全连接神经网络相比，LSTM 网络能够在时间维度上保留历史信息，并通过门控机制学习长期依赖关系，因此非常适合处理空气质量预测这类具有时间连续性的问题。

二、原理

空气质量预测问题本质上属于多变量时间序列预测问题。设在时刻 t 的观测数据为：

$$x_t = [pollution_t, dew_t, temp_t, press_t, wnd_dir_t, wnd_spd_t, snow_t, rain_t]$$

其中，pollution 表示 PM2.5 浓度，dew 表示露点，temp 表示温度，press 表示气压，wnd_dir 表示风向，wnd_spd 表示风速，snow 表示累计降雪时长，rain 表示累计降雨时长。

本实验的任务是利用过去一段时间内的多变量序列数据：

$$[x_{t-L}, x_{t-L+1}, \cdots, x_{t-1}]$$

预测下一时刻的 PM2.5 浓度：

$$\hat{y}_t = pollution_t$$

其中，L 表示回看窗口长度。本实验中设置 lookback = 24，即利用过去 24 小时的数据预测下一小时的 PM2.5 浓度。

LSTM，即长短期记忆网络，是循环神经网络 RNN 的一种改进结构。传统 RNN 在处理长序列数据时，容易出现梯度消失或梯度爆炸问题，导致模型难以学习较长时间范围内的依赖关系。LSTM 通过引入细胞状态和门控机制，有效缓解了这一问题。

LSTM 主要由遗忘门、输入门和输出门组成。

遗忘门用于决定上一时刻的状态信息有多少需要被保留，其表达式为：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

输入门用于决定当前输入信息有多少需要写入细胞状态，其表达式为：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\widetilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

细胞状态更新公式为：

$$C_t = f_t * C_{t-1} + i_t * \widetilde{C}_t$$

输出门用于决定当前时刻输出的隐藏状态，其表达式为：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t * \tanh(C_t)$$

通过上述门控结构，LSTM 能够根据输入数据自动选择保留、遗忘或输出部分历史信息。因此，对于 PM2.5 预测这种与历史气象条件和污染累积状态密切相关的问题，LSTM 具有较好的适用性。

三、数据预处理与特征工程

3.1 数据集介绍

本实验使用的数据集为 Air Quality Dataset。数据集中每一行代表一个小时的空气质量和气象观测数据，主要字段如下：

字段名	含义
date	时间
pollution	PM2.5 浓度
dew	露点

字段名	含义
temp	温度
press	气压
wnd_dir	风向
wnd_spd	累计风速
snow	累计降雪时长
rain	累计降雨时长

该数据集同时包含目标变量和多个外部影响因素，因此适合用于多变量时间序列预测任务。

3.2 数据清洗

在模型训练之前，需要对数据进行清洗和整理。首先，将时间字段 date 转换为标准时间格式，并按照时间先后顺序进行排序，以保证样本之间的时间关系正确。

其次，处理数据中的缺失值。本实验采用前向填充和后向填充相结合的方式进行缺失值处理。前向填充是使用上一时刻的有效值填补当前缺失值，后向填充是使用后一时刻的有效值进行补充。若经过填充后仍存在缺失值，则删除对应记录。

最后，保留与预测任务相关的主要特征，包括 pollution、dew、temp、press、wnd_dir、wnd_spd、snow 和 rain，并去除无关字段。

3.3 类别变量编码

数据中的风向 wnd_dir 属于类别变量，不能直接作为数值输入到神经网络中。因此，本实验采用 One-Hot 编码方法对风向进行处理。

One-Hot 编码会将不同风向转换为多个二值特征。例如，不同的风向类别会被转换为由 0 和 1 组成的向量。这样既避免了直接用数字表示类别带来的大小关系误解，也使模型能够学习不同风向对 PM2.5 浓度变化的影响。

3.4 特征归一化

由于不同特征的量纲和数值范围差异较大，例如气压通常在 1000 左右，而降雨和降雪时长可能较小。如果直接将这些数据输入神经网络，可能会导致模型训练不稳定，甚至影响收敛速度。

因此，本实验采用 Min-Max 归一化方法，将所有特征缩放到 0 到 1 的范围内。其计算公式为：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

归一化后，各特征处于相近的数值范围，有利于神经网络进行参数更新和模型训练。

3.5 构造 LSTM 输入样本

LSTM 模型的输入数据需要是三维结构，其格式为：

$$(samples, timesteps, features)$$

其中，samples 表示样本数量，timesteps 表示时间步长度，features 表示每个时间步包含的特征数量。

本实验设置 lookback = 24，即使用过去 24 小时的数据预测下一小时的 PM2.5 浓度。具体来说，对于第 i 个样本：

输入数据为：

$$X_i = [x_{i-24}, x_{i-23}, \cdots, x_{i-1}]$$

输出标签为：

$$y_i = pollution_i$$

通过滑动窗口方法，可以将原始时间序列数据转换为适合 LSTM 模型训练的监督学习样本。

四、模型架构与训练特性分析

4.1 模型结构

本实验采用双层 LSTM 网络结构进行 PM2.5 浓度预测。模型整体结构如下：

层次	参数设置	作用
LSTM 层 1	64 个神经元，return_sequences=True	提取初步时间序列特征
Dropout 层 1	dropout = 0.2	降低过拟合风险
LSTM 层 2	32 个神经元	提取更高层时序特征
Dropout 层 2	dropout = 0.2	提高泛化能力

层次	参数设置	作用
Dense 层	16 个神经元，ReLU 激活函数	非线性特征映射
输出层	1 个神经元	输出预测 PM2.5 浓度

第一层 LSTM 设置 return_sequences=True，是为了将完整的时间序列隐藏状态传递给第二层 LSTM。第二层 LSTM 输出最终的序列特征表示，再经过全连接层得到预测结果。

Dropout 层的作用是在训练过程中随机丢弃部分神经元连接，从而减少模型对训练数据的过度依赖，提高模型在测试集上的泛化能力。

4.2 训练参数

模型训练过程中的主要参数如下：

参数	数值
回看窗口 lookback	24
测试集比例 test_ratio	0.2
最大训练轮数 epochs	30
批大小 batch_size	64
优化器	Adam
损失函数	MSE
评价指标	MAE
Dropout 比例	0.2

本实验采用 Adam 优化器进行模型参数更新。Adam 结合了动量法和自适应学习率方法，具有收敛速度快、训练稳定等优点，常用于深度学习模型训练。

损失函数采用均方误差 MSE，其表达式为：

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

其中，y_i 表示真实值，\hat{y}_i 表示预测值，n 表示样本数量。

4.3 训练策略

为了防止过拟合并保存最佳模型，本实验使用了 EarlyStopping 和 ModelCheckpoint 两种训练策略。

EarlyStopping 用于监控验证集损失 val_loss。如果验证集损失在连续若干轮训练中没有继续下降，则提前停止训练，并恢复验证集表现最好的模型参数。

ModelCheckpoint 用于在训练过程中保存验证集损失最低的模型。本实验最终保存的最佳模型文件为：

$$best_lstm_model.keras$$

在时间序列任务中，数据不能随机打乱，因此本实验按照时间顺序划分训练集和测试集，并在模型训练时设置 shuffle=False，以保证时间序列的连续性。

4.4 训练特性分析

从训练曲线可以看出，模型在前几轮训练中损失下降速度较快，说明模型能够较快学习到数据中的主要规律。随着训练轮数增加，训练损失和验证损失逐渐趋于稳定，表明模型已经基本收敛。

验证集损失整体上没有出现持续上升现象，说明当前模型没有明显的严重过拟合问题。训练集损失和验证集损失之间差距较小，也说明模型具有一定的泛化能力。

五、实验结果与分析

5.1 评价指标

本实验采用 MAE 和 RMSE 作为模型预测性能的评价指标。

平均绝对误差 MAE 的计算公式为：

$$MAE = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|$$

均方根误差 RMSE 的计算公式为：

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}$$

MAE 反映预测值与真实值之间的平均绝对偏差，数值越小，说明模型整体预测误差越小。RMSE 对较大的预测误差更加敏感，因此可以反映模型在峰值或异常波动情况下的表现。

5.2 实验结果

模型在测试集上的实验结果如下：

指标　数值

MAE　17.9879

RMSE 27.3329

由结果可知，模型在测试集上的平均绝对误差约为 18，均方根误差约为 27.33。该结果说明模型能够较好地预测 PM2.5 浓度，整体误差处于可以接受的范围内。

5.3 训练曲线分析

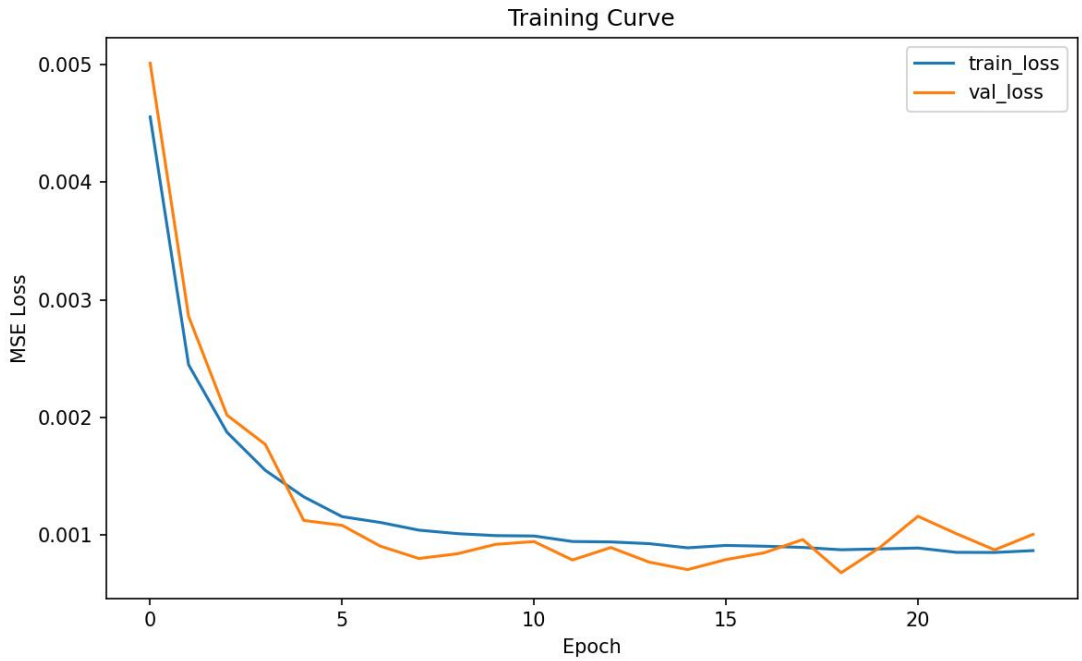

图 1 LSTM 模型训练损失曲线

从训练曲线可以看出，训练集损失和验证集损失在前几轮均快速下降，说明模型能够有效学习空气质量数据中的时序特征。随后，损失曲线逐渐趋于平稳，表明模型训练已经基本收敛。

训练后期，验证集损失存在一定小幅波动，但没有出现明显持续上升趋势。因此，可以认为模型整体训练过程较为稳定，没有出现严重过拟合现象。

5.4 预测结果分析

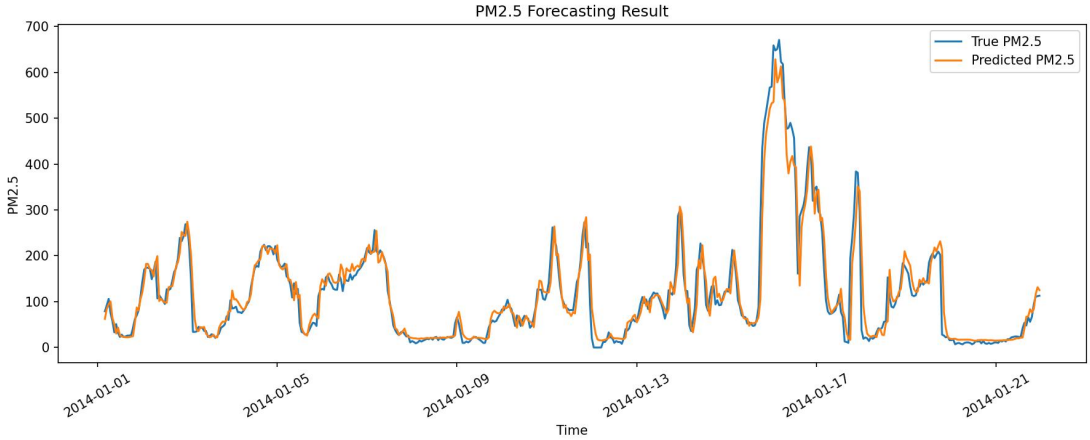

图 2 PM2.5 真实值与预测值对比曲线

从预测结果对比图可以看出，模型预测曲线与真实曲线整体趋势较为一致。无论是在 PM2.5 浓度较低的平稳区间，还是在污染浓度上升和下降的变化区间，预测结果都能够较好地跟随真实值变化。

但是，在部分污染浓度突然升高或降低的峰值区域，预测曲线相较真实曲线略显平滑，峰值预测结果存在一定偏低现象。这说明 LSTM 模型虽然能够学习整体变化趋势，但对突发性极端污染事件的捕捉能力仍然有限。

造成该现象的原因可能包括以下几点：

第一，极端污染峰值在整个数据集中出现频率较低，模型在训练过程中学习到的样本不足。

第二，模型使用 MSE 作为损失函数，更倾向于拟合整体平均趋势，因此在峰值区域可能出现预测平滑现象。

第三，当前模型只使用过去 24 小时的数据进行预测，对于更长时间范围内的污染累积和气象变化考虑不足。

第四，当前特征主要包括基础气象信息，尚未引入季节、节假日、污染源变化等更复杂因素。

5.5 改进方向

为了进一步提高预测效果，可以从以下几个方面进行改进。

首先，可以增大回看窗口长度。例如将 lookback 从 24 增加到 48 或 72，使模型能够利用更长时间范围内的历史信息。

其次，可以进一步调整模型结构。例如尝试 GRU、双向 LSTM、CNN-LSTM 或引入 Attention 机制，以增强模型对复杂时间序列模式的表达能力。

再次，可以加入更多时间特征。例如将小时、星期、月份、季节等信息加入输入特征，使模型能够学习空气污染变化中的周期性规律。

最后，可以针对峰值预测不足的问题改进损失函数，例如尝试 Huber Loss，或者对高污染样本赋予更高权重，从而提高模型对极端污染情况的预测能力。

结论

本文基于 Kaggle 空气质量数据集，设计并实现了一个基于 LSTM 的多变量 PM2.5 浓度预测模型。实验首先对原始数据进行了时间排序、缺失值处理、类别变量编码和特征归一化，然后通过滑动窗口方法将时间序列数据转换为监督学习样本，最后使用双层 LSTM 网络对下一小时 PM2.5 浓度进行预测。

实验结果表明，模型在测试集上取得了 MAE = 17.9879、RMSE = 27.3329 的预测效果。从训练曲线来看，模型损失在训练过程中逐渐下降并趋于稳定，说明模型能够有效收敛。从预测结果对比图来看，模型预测值与真实值整体趋势较为一致，能够较好地反映 PM2.5 浓度的变化规律。

但是，模型在部分突发峰值区域仍存在预测偏低和平滑现象，说明其对极端污染变化的捕捉能力还有提升空间。后续可以通过增加历史时间窗口、引入更多特征、优化模型结构和改进损失函数等方式进一步提升预测性能。

总体而言，基于 LSTM 的多变量空气质量预测方法能够较好地利用历史污染数据和气象数据，对 PM2.5 浓度进行有效预测，具有一定的实际应用价值。