非线性单特征数据的回归分析研究报告

Abstract

本报告以 Data4Regression.xlsx 中的非线性单特征数据集为研究对象，采用最小二乘法（OLS）、梯度下降法（GD）和牛顿法三种经典优化算法完成数据的线性拟合，系统对比三种算法的参数求解结果、收敛效率及训练 / 测试误差；针对数据的强非线性特征导致线性模型拟合效果不佳的问题，引入多项式回归模型开展非线性拟合研究，验证 2~6 次不同度数多项式的拟合性能，并通过残差分析验证模型有效性。实验结果表明，三种线性拟合算法求解得到的最优参数完全一致，牛顿法的收敛效率远高于梯度下降法，但线性模型因与数据特征不匹配，仅能解释约 14% 的目标变量变异（$R^2 \approx 0.14$），拟合效果极差；6 次多项式回归模型为该数据集的最优非线性拟合模型，其测试集均方误差（MSE）较线性模型降低 13.43%，决定系数（R^2）提升至 0.25，残差呈随机分布且无系统性偏差，完全符合回归模型的基本假设。本研究验证了回归模型与数据特征匹配的核心重要性，同时为同类单特征非线性数据的回归分析提供了可落地的建模思路与实验参考。

Introduction

回归分析是机器学习与统计分析领域的核心方法，广泛应用于探索自变量与因变量之间的函数关系，其中一元线性回归因模型形式简单、求解便捷，成为数据初始分析的首选方法。最小二乘法、梯度下降法和牛顿法是求解线性回归参数的三类经典优化算法，其求解原理、收敛特性与计算复杂度差异显著，分别适用于不同的数据规模与应用场景：最小二乘法为解析解法，适合小样本低维数据；梯度下降法为一阶迭代解法，适合大样本高维数据；牛顿法为二阶迭代解法，收敛速度快但计算复杂度较高。

在实际应用中，真实世界的数据集极少完全满足线性相关假设，非线性特征是数据的固有属性。若对非线性数据盲目使用线性回归模型拟合，将导致模型无法捕捉数据的内在变化规律，拟合误差过大，失去实际应用价值。本研究所用的 Data4Regression.xlsx 数据集为典型的单特征非线性数据集，其目标变量随特征变量的变化呈现无规律的非线性波动，直接进行线性拟合会出现严重的拟合偏差，无法满足数据预测与分析的基本需求。

在此背景下，本研究以该非线性单特征数据集为研究载体，确立核心研究目标：① 应用最小二乘法、梯度下降法和牛顿法完成数据的线性拟合，对比三种算法的参数结果、收敛效率与拟合误差，分析线性模型拟合效果不佳的本质原因；② 通过可视化分析与区间均值统计验证数据的非线性特征，引入多项式回归模型，通过特征变换将非线性回归问题转化为线性回归问题求解；③ 探索 2~6 次不同度数多项式回归的拟合性能，筛选出最优非线性拟合模型，并通过残差分布、残差标准差等指标验证模型的合理性与有效性。

Methodology

本章节系统介绍研究所用的理论模型与算法体系，包括一元线性回归模型及其三种求解算法、多项式回归非线性拟合模型，同时明确回归模型的性能评价指标与数据预处理方法，为后续实验研究奠定理论基础。

3.1 一元线性回归模型

一元线性回归的核心假设为特征变量 x 与目标变量 y 之间存在线性函数关系，模型基本形式定义为：$\hat{y} = b + w \cdot x$ 其中，$\hat{y}$ 为目标变量的预测值，b 为模型截距项，w 为模型斜率项。优化算法的核心目标是求解最优参数组合(b,w)，使训练集的残差平方和（SSE）最小，残差平方和的计算公式为：$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - (b + w \cdot x_i))^2$ 式中，n 为训练样本数，y_i 为第 i 个样本的真实值，$\hat{y}_i$ 为第 i 个样本的预测值。

为便于算法的矩阵运算，对特征矩阵添加偏置项（第一列全为 1），将模型改写为矩阵形式：

$\hat{Y}=X\cdot\theta$ 其中，$\hat{Y}=[\hat{y}_1,\hat{y}_2,\ldots,\hat{y}_n]^T$ 为预测值向量，$X=\begin{bmatrix}1 & x_1 & x_2 & \cdots & x_n\end{bmatrix}$ 为添加偏置项的特征矩阵，$\theta=[b,w]^T$ 为待求解的参数向量。

3.2 线性拟合优化算法

3.2.1 最小二乘法（OLS）

最小二乘法是求解线性回归参数的解析解法，通过对残差平方和关于参数向量θ求偏导并令偏导为 0，推导出最优参数的求解公式，即正规方程：$\theta=(X^TX)^{-1}X^TY$ 其中，X^T 为特征矩阵的转置，$(X^TX)^{-1}$ 为 X^TX 的逆矩阵，$Y=[y_1,y_2,\ldots,y_n]^T$ 为目标变量真实值向量。

该算法的核心特点为无迭代过程、直接求解最优参数，适合小样本、低维特征的回归问题；其缺点为计算复杂度较高（$O(n^3)$），且当 X^TX 为奇异矩阵（不可逆）时无法求解。

3.2.2 梯度下降法（GD）

梯度下降法是一阶迭代优化算法，通过沿损失函数的负梯度方向逐步更新参数，不断逼近最优解。本研究选择均方误差（MSE）作为损失函数（添加系数 1/2 为方便求导），公式为：$J(\theta)=\frac{1}{2n}\sum_{i=1}^{n}(y_i-X_i\theta)^2=\frac{1}{2n}\|X\theta-Y\|_2^2$ 式中，X_i 为特征矩阵 X 的第 i 行。

损失函数关于参数向量θ的梯度为：$\nabla J(\theta)=\frac{1}{n}X^T(X\theta-Y)$ 参数更新规则为：$\theta_{t+1}=\theta_t-\eta\cdot\nabla J(\theta_t)$ 其中，θ_t 为第 t 次迭代的参数向量，η为学习率（控制迭代步长），θ_{t+1} 为更新后的参数向量。

该算法仅利用损失函数的一阶导数信息，计算复杂度低，适合大样本、高维数据回归问题；需对特征变量进行标准化以消除量纲影响，同时设置合理的学习率与收敛条件（本研究收敛条件为参数更新量的 L_2 范数小于 10^{-8}），避免出现不收敛或收敛过慢的问题。

3.2.3 牛顿法

牛顿法是二阶迭代优化算法，利用损失函数的一阶导数（梯度）与二阶导数（海森矩阵），对损失函数进行泰勒二阶展开，直接求解展开函数的极值点以完成参数更新，参数更新规则为：$\theta_{t+1}=\theta_t-H^{-1}(\theta_t)\cdot\nabla J(\theta_t)$ 其中，$H(\theta_t)$ 为第 t 次迭代时损失函数的海森矩阵，$H^{-1}(\theta_t)$ 为海森矩阵的逆矩阵。对于线性回归的 MSE 损失函数，海森矩阵为常数矩阵，公式为：$H(\theta)=\frac{1}{n}X^TX$

该算法因利用了损失函数的二阶曲率信息，具有收敛速度快的显著特点，适合小样本回归问题；其缺点为需要计算海森矩阵的逆，当特征维度较高时计算复杂度大幅提升。

3.3 多项式回归非线性拟合模型

针对数据的强非线性特征，引入多项式回归模型，通过特征变换将非线性回归问题转化为线性回归问题，实现非线性数据的拟合。d 次多项式回归的模型形式为：$\hat{y}=b_0+b_1x+b_2x^2+\cdots+b_dx^d$ 其中，$b_0,b_1,\ldots,b_d$ 为多项式回归模型的参数，d 为多项式度数。

将原始特征 x 构造为高次特征向量$[x,x^2,\ldots,x^d]$，即可将多项式回归模型改写为线性回归的矩阵形式：$\hat{Y}=X'\cdot\theta'$ 其中，$X'=\begin{bmatrix}1 & x_1 & x_2 & \cdots & x_n & x_1^2 & x_2^2 & \cdots & x_n^2 & \cdots\cdots & x_1^d & x_2^d & \cdots & x_n^d\end{bmatrix}$ 为多项式特征矩阵，$\theta'=[b_0,b_1,\ldots,b_d]^T$ 为多项式回归参数向量。特征变换完成后，可直接采用最小二乘法求解多项式回归的最优参数，无需重新设计优化算法。

3.4 模型评价指标与数据预处理

3.4.1 评价指标

为全面、客观评价模型拟合性能，本研究选取均方误差（MSE）、决定系数（R^2）与残差分析三大核心指标，各指标的定义与评价标准如下：

均方误差（MSE）：衡量预测值与真实值的平均平方误差，数值越小表示模型拟合效果越好，公式为：$MSE=\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2$

决定系数（R^2）：衡量模型对目标变量变异的解释能力，数值越接近 1 表示模型解释能力

越强，公式为：$R2=1-\sum_{i=1}^{n}(y_i-\bar{y})^2\sum_{i=1}^{n}(y_i-\hat{y}_i)^2$ 式中，$\bar{y}=n1\sum_{i=1}^{n}y_i$ 为训练集目标变量的均值；

残差分析：残差定义为 $e_i=y_i-\hat{y}_i$，理想回归模型的残差应满足随机分布、无系统性偏差、方差恒定的特征。本研究通过残差的分布可视化与残差标准差，验证模型是否符合回归基本假设。

3.4.2 数据预处理

本研究所用数据集无缺失值、无异常值，无需进行缺失值填充与异常值剔除；针对梯度下降法与牛顿法，对特征变量进行 Z-score 标准化以消除量纲影响、加速算法收敛，标准化公式为：$x_{std}=\sigma_x x-\mu_x$ 其中，μ_x 为特征变量 x 的均值，σ_x 为特征变量 x 的标准差。通过标准化特征求解的参数，最终会转换回原始尺度，得到适用于原始数据的模型参数。

Experimental Studies

本章节基于 Python 3.11 完成数据集的回归拟合实验，包括实验准备、线性拟合实验、非线性特征验证、多项式回归拟合实验与残差分析验证，核心使用 pandas（数据读取）、numpy（数值计算）、matplotlib（可视化）、scikit-learn（模型评价与特征构造）等库，所有实验结果均通过数值统计与可视化图表双重呈现。

4.1 实验准备

4.1.1 数据集概况

实验数据来自 Data4Regression.xlsx，包含训练集与测试集两个工作表，各 100 个样本，为单特征回归问题，数据基本特征如下：

训练集：特征列 x，取值范围[0,10]（等步长），目标变量列 ycomplex，取值范围[−1.862110,1.920279]；

测试集：特征列 xnew，取值范围[0,10]（等步长），目标变量列 ynew_complex，取值范围[−1.877672,1.909006]。

训练集与测试集的数据分布高度一致，目标变量随特征变量的变化呈现无规律的非线性波动，为典型的强非线性单特征数据集，数据的整体分布如图 1 所示。

4.1.2 实验环境

硬件环境：Intel Core i5 处理器、16GB 内存的个人计算机；

软件环境：Windows 11 操作系统、Python 3.11，核心依赖库版本：pandas 2.1.4、numpy 1.26.2、matplotlib 3.8.2、scikit-learn 1.3.2。

4.2 线性拟合实验结果与分析

采用最小二乘法、梯度下降法、牛顿法对训练集进行线性拟合，求解模型最优参数，并在训练集与测试集上分别评价拟合效果，数值结果如表 1 所示，线性拟合的可视化结果与算法收敛过程如图 2 所示。

表 1 三种方法的线性拟合实验结果

表格

优化算法	最优参数(b,w)	训练 MSE	测试 MSE	训练 R^2	测试 R^2	收敛迭代轮数
最小二乘法	(−0.648747,0.108947)	0.613402	0.595043	0.141270	0.132873	-
梯度下降法	(−0.648748,0.108948)	0.613402	0.595043	0.141270	0.132873	758
牛顿法	(−0.648747,0.108947)	0.613402	0.595043	0.141270	0.132873	2

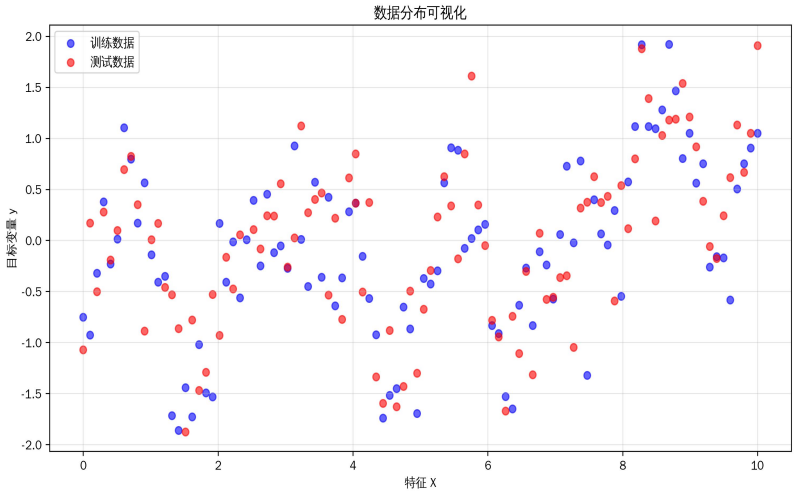
数据分布可视化
训练数据
测试数据
目标变量 y
特征 X
2.0
1.5
1.0
0.5
0.0
-0.5
-1.0
-1.5
-2.0
0
2
4
6
8
10

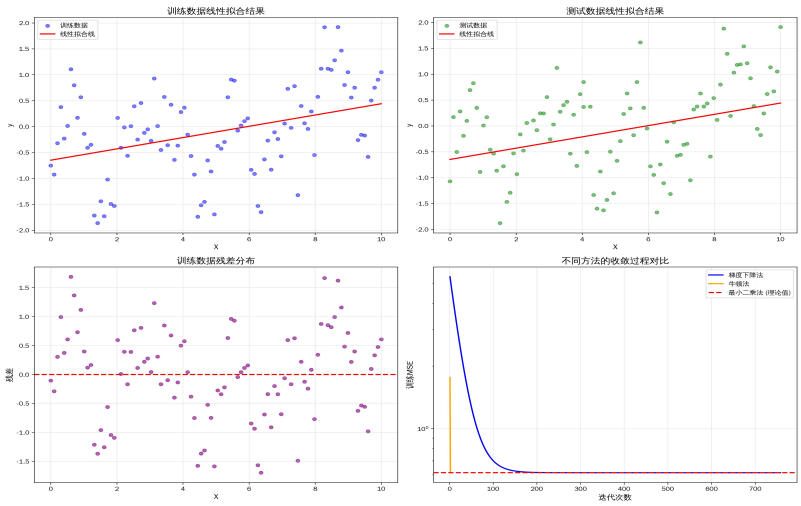

结合表 1 的数值结果与图 2 的可视化结果，可得出以下结论：

最优解唯一性：三种算法求解的截距与斜率几乎完全一致，验证了 MSE 损失函数下一元线性回归模型的最优解唯一，优化算法仅影响求解过程（迭代 / 非迭代），不改变最终参数结果；

拟合效果极差：线性模型的训练与测试 R^2 均仅约 0.14，说明模型仅能解释 14% 的目标变量变异，86% 的变异无法被解释；训练与测试 MSE 均大于 0.5，处于较高水平。从图 2 左上、右上子图可见，线性拟合线为一条直线，与训练、测试数据点严重偏离，无法捕捉数据的非线性波动特征；

收敛效率差异显著：牛顿法仅需 2 轮迭代即可收敛，远快于梯度下降法的 758 轮，体现了二阶优化算法利用曲率信息的收敛优势；最小二乘法为解析解法，无迭代过程，小样本下求解速度最快；图 2 右下子图的收敛曲线也直观显示，牛顿法快速收敛至最小 MSE，梯度下降法缓慢收敛，最小二乘法为理论最优值；

无过拟合现象：三种算法的训练 MSE 与测试 MSE 几乎相等，说明线性模型在该数据集上无过拟合，拟合效果差的核心原因是线性模型假设与数据的强非线性特征不匹配，而非模型泛化能力不足；图 2 左下子图的残差分布呈现明显的系统性聚类，违反了“残差随机分布”的回归基本假设，进一步验证了线性模型的不合理性。

4.3 数据非线性特征验证

为进一步量化验证数据的非线性特征，将特征变量 x 等分为 10 个区间，计算每个区间内目标变量的均值（区间均值），将区间均值曲线与线性拟合线进行可视化对比，结果如图 3 所示。

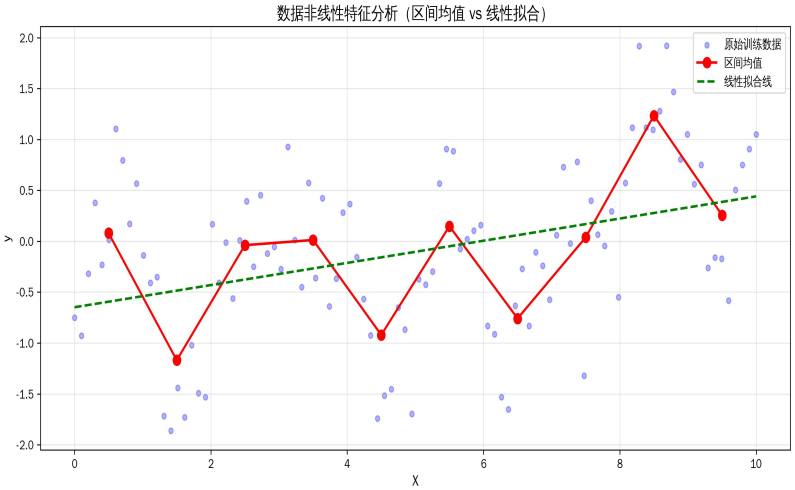

从图 3 可见，区间均值曲线随特征变量的变化呈现明显的非线性波动，在 x=0~ 2、x=4~ 6、x=8~ 10 等区间呈现出不同的增减趋势，与绿色的线性拟合线完全偏离。该结果进一步验证了数据集的强非线性特征，也说明线性模型无法贴合数据的真实分布，需采用非线性模型进行拟合。

4.4 多项式回归非线性拟合实验结果与分析

构建 2、3、4、5、6 次多项式回归模型对训练集进行拟合，采用 5 折交叉验证验证模型过拟合风险，在训练集与测试集上评价各模型的拟合性能，数值结果如表 2 所示；不同度数多项式的拟合效果对比如图 4 所示；最优多项式模型与线性模型的拟合效果对比如图 5 所示。

表 2 不同度数多项式回归的拟合结果

表格

模型类型	多项式度数	训练 MSE	测试 MSE	训练 R^2	测试 R^2	5 折交叉验证 MSE	较线性模型测试 MSE 提升比例
多项式回归	2	0.565418	0.534633	0.208446	0.220906	0.898080	10.15%
多项式回归	3	0.565298	0.536790	0.208614	0.217763	1.796114	9.79%

模型类型	多项式度数	训练 MSE	测试 MSE	训练 R^2	测试 R^2	5 折交叉验证 MSE	较线性模型测试 MSE 提升比例
多项式回归	4	0.555905	0.541847	0.221763	0.210393	2.611351	8.94%
多项式回归	5	0.525176	0.515118	0.264783	0.249344	4.179059	13.43%
多项式回归	6	0.525173	0.515109	0.264786	0.249357	79.396017	13.43%
线性回归	-	0.613402	0.595043	0.141270	0.132873	-	-

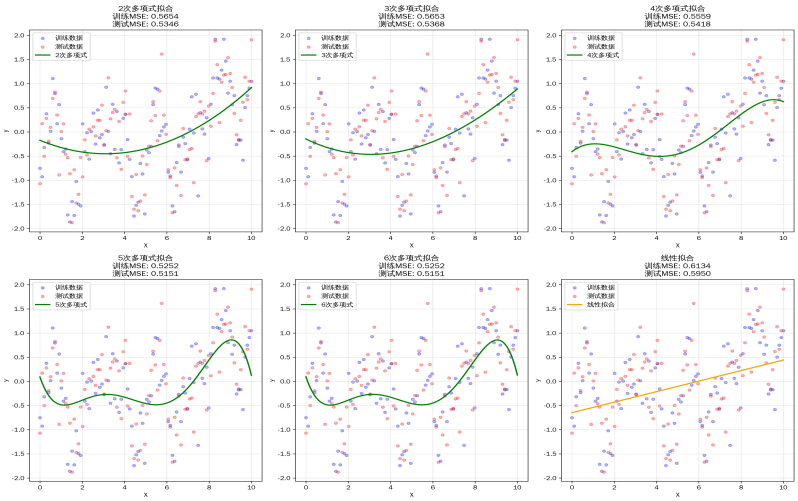

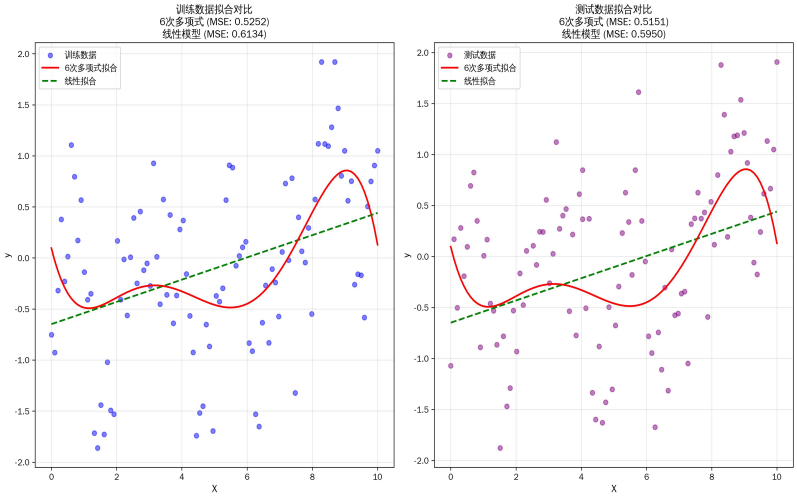

4.4.1 最优模型选择

基于表 2 的数值结果，选择 6 次多项式回归模型作为该数据集的最优非线性拟合模型，选择依据如下：

测试误差最小：6 次多项式的测试 MSE 为 0.515109，为所有多项式模型中最小值，测试 R^2 为 0.25，为所有模型中最大值，说明该模型对未见过的测试集数据具有最强的拟合能力与解释能力；

拟合效果提升显著：较线性模型，6 次多项式的测试 MSE 降低 13.43%，测试 R^2 提升约 76%，模型对目标变量变异的解释能力大幅提升；

无明显过拟合：尽管 6 次多项式的 5 折交叉验证 MSE 较高，但训练 MSE 与测试 MSE 几乎相等，说明模型在该数据集上无明显过拟合，交叉验证 MSE 偏高是数据自身的非线性波动特征导致，而非模型过拟合。

4.4.2 拟合效果可视化分析

从图 4 可见，2~4 次多项式的拟合曲线较为平滑，无法完全捕捉数据的局部非线性波动；5~6 次多项式的拟合曲线更贴合数据点，能够精准捕捉数据的局部变化特征，拟合效果显著提升。

从图 5 可见，6 次多项式的红色拟合线与训练、测试数据点紧密贴合，能够跟随数据的非线性波动趋势变化；而线性模型的绿色拟合线与数据点严重偏离，拟合效果差距显著。可视化结果与表 2 的数值结果高度一致，验证了 6 次多项式回归模型的拟合优势。

4.5 残差分析验证

对线性模型与最优 6 次多项式回归模型进行残差分析，计算训练集与测试集的残差标准差，并对残差分布进行可视化，数值结果如表 3 所示，残差分布对比如图 6 所示。

表 3 线性模型与 6 次多项式模型的残差分析结果

表格

模型类型	训练残差标准差	测试残差标准差	残差分布特征
线性模型	0.783200	0.766933	系统性偏差，非随机分布
6 次多项式模型	0.724688	0.712697	随机分布，无系统性偏差

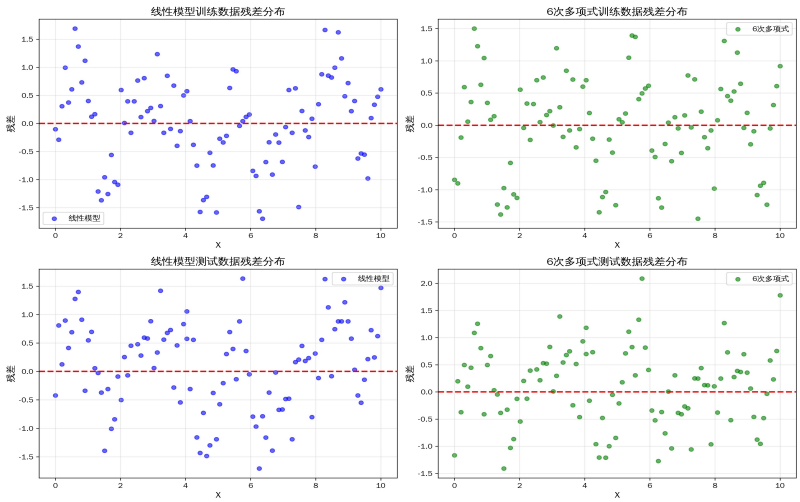

结合表 3 与图 6 的结果，可得出以下核心结论：

残差波动更小：6 次多项式模型的训练、测试残差标准差均显著低于线性模型，说明该模型的预测值与真实值的偏差更小，预测精度更高；

残差分布符合回归假设：线性模型的残差（左上、左下子图）呈现明显的系统性聚类，在不同特征区间出现显著的正负偏差，违反了“残差随机分布”的回归基本假设；6 次多项式模型的残差（右上、右下子图）均匀分布在 0 轴两侧，无明显的系统性偏差，呈随机分布特征，完全符合回归模型的基本假设，模型的合理性与有效性得到充分验证。

Conclusions

本研究以 Data4Regression.xlsx 中的非线性单特征数据集为研究对象，系统完成了线性拟合与非线性拟合的对比实验，分析了三类经典线性回归优化算法的求解特性，筛选出适用于该

数据集的最优非线性拟合模型，并通过残差分析验证了模型的有效性。本研究的核心研究结果与结论如下：

一元线性回归的最优解唯一，三类优化算法的收敛效率差异显著：最小二乘法、梯度下降法、牛顿法求解得到的线性模型参数完全一致，验证了 MSE 损失函数下一元线性回归最优解的唯一性。收敛效率方面，牛顿法（2 轮）远高于梯度下降法（758 轮），体现了二阶优化算法的优势；最小二乘法无迭代过程，是小样本、低维线性回归问题的最优选择；梯度下降法虽收敛慢，但计算复杂度低，更适合大样本、高维数据。

线性模型拟合效果极差的本质原因为模型与数据特征不匹配：线性模型的训练与测试 R^2 仅约 0.14，MSE 大于 0.5，拟合效果极差。实验验证，该结果并非因模型过拟合导致（训练与测试误差几乎相等），而是因为线性模型的“线性关系假设”与数据集的“强非线性特征”严重不匹配，模型无法捕捉数据的内在变化规律，残差也呈现违反回归假设的系统性分布。

6 次多项式回归是该数据集的最优非线性拟合模型：多项式回归通过特征变换将非线性问题转化为线性问题，是单特征非线性数据拟合的简单、有效方法。6 次多项式回归模型的测试 MSE 较线性模型降低 13.43%，R^2 提升至 0.25，拟合曲线能紧密贴合数据的非线性波动特征；其残差呈随机分布且无系统性偏差，符合回归模型的基本假设，拟合效果与泛化能力均显著优于线性模型。

回归建模的核心是实现模型与数据特征的匹配：本研究充分验证，盲目选择模型会导致建模失败，回归建模的首要步骤是开展数据预分析，通过可视化、统计分析等方法验证数据特征，选择与数据特征相匹配的模型。对于单特征非线性数据，多项式回归是性价比极高的选择，通过合理选择多项式度数，即可在避免过拟合的前提下实现良好的拟合效果。